

USO DE REDES NEURAIS RECORRENTES PARA
PREVISÃO DE SÉRIES TEMPORAIS
FINANCEIRAS

DAVID MICHAEL QUIRINO NELSON

**USO DE REDES NEURAIS RECORRENTES PARA
PREVISÃO DE SÉRIES TEMPORAIS
FINANCEIRAS**

Dissertação apresentada ao Programa de Pós-Graduação em Ciência da Computação do Instituto de Ciências Exatas da Universidade Federal de Minas Gerais como requisito parcial para a obtenção do grau de Mestre em Ciência da Computação.

ORIENTADOR: ADRIANO CÉSAR MACHADO PEREIRA

Belo Horizonte
Fevereiro de 2017

© 2017, David Michael Quirino Nelson.
Todos os direitos reservados.

Nelson, David Michael Quirino

N425u Uso de redes neurais recorrentes para previsão de
séries temporais financeiras / David Michael Quirino
Nelson. — Belo Horizonte, 2017
xviii, 55 f. : il. ; 29cm

Dissertação (mestrado) — Universidade Federal de
Minas Gerais

Orientador: Adriano César Machado Pereira

1. Computação - Teses. 2. Mercado de ações -
Previsão. 3. Aprendizado de Máquina. 4. Redes neurais
(Computação). I. Orientador. II. Título.

CDU 519.6*82 (043)



UNIVERSIDADE FEDERAL DE MINAS GERAIS
INSTITUTO DE CIÊNCIAS EXATAS
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

FOLHA DE APROVAÇÃO

Uso de redes neurais recorrentes para previsão de séries temporais financeiras

DAVID MICHAEL QUIRINO NELSON

Dissertação defendida e aprovada pela banca examinadora constituída pelos Senhores:

PROF. ADRIANO CÉSAR MACHADO PEREIRA - Orientador
Departamento de Ciência da Computação - UFMG

PROF. ADRIANO ALONSO VELOSO
Departamento de Ciência da Computação - UFMG

PROF. CRISTIANO ARBEX VALLE
Departamento de Ciência da Computação - UFMG

PROF. FELIPE DIAS PAIVA
Departamento de Ciências Sociais Aplicadas - CEFETMG

Belo Horizonte, 24 de fevereiro de 2017.

Agradecimentos

Agradeço especialmente aos meus pais e irmã pelo apoio, suporte e incentivo fundamentais durante essa jornada.

Também ao meu orientador, Adriano Pereira, por ter sido meu guia e contribuído com uma ajuda imensurável em todos os momentos, tornando esse trabalho possível.

Um agradecimento também aos meus amigos e pessoas próximas que se fizeram sempre presentes, sempre companheiros.

Agradeço ao Programa de Pós Graduação em Ciência da Computação da Universidade Federal de Minas Gerais, pela oportunidade e privilégio de realizar este trabalho, e sobretudo pelo aprendizado. Estendo esse agradecimento ao corpo docente e discente, com quem tanto aprendi durante esse período.

Resumo

Prever variações de preço em bolsas de valores é um grande desafio devido ao fato que este é um ambiente imensamente complexo, caótico e dinâmico. Existem diversos estudos de variadas áreas buscando encarar tal desafio, e abordagens baseadas em Aprendizado de Máquina são o foco de muitos deles. Existem vários exemplos em que algoritmos de Aprendizado de Máquina foram capazes de alcançar resultados satisfatórios quando realizando tal tipo de previsão. Este trabalho estuda a aplicação de redes *Long Short-Term Memory* no problema de previsão de tendências de preços de ações e com base no histórico de preços juntamente com indicadores de análise técnica. Para este objetivo, um modelo de previsão foi projetado, uma série de experimentos foi executada e seus resultados analisados em relação a uma variedade de métricas para avaliar se este tipo de algoritmo apresenta melhorias quando comparado com outros métodos de Aprendizado de Máquina e estratégias de investimento. Os resultados obtidos foram satisfatórios, obtendo uma acurácia média de até 55,9% ao prever se o preço de uma determinada ação irá subir ou não no futuro imediato. O modelo também foi avaliado sob aspectos financeiros mostrando resultados promissores em termos de retorno financeiro.

Palavras-chave: Mercado de Ações, Análise Técnica, Aprendizado de Máquina, *Deep Learning*, *Long Short-Term Memory*, Redes Neurais Artificiais, Redes Neurais Recorrentes.

Abstract

Predictions on stock market prices are a great challenge due to the fact that it is an immensely complex, chaotic and dynamic environment. There are many studies from various areas aiming to take on that challenge and Machine Learning approaches have been the focus of many of them. There are many examples of Machine Learning algorithms being able to reach satisfactory results when doing that type of prediction. This project studies the usage of LSTM networks on that scenario, to predict future trends of stock prices based on the price history, alongside with technical analysis indicators. For that goal, a prediction model was built, and a series of experiments were executed and their results analyzed against a number of metrics to assess if this type of algorithm presents any improvements when compared to other Machine Learning methods and investment strategies. The results that were obtained are promising, getting up to an average of 55.9% of accuracy when predicting if the price of a particular stock is going to go up or not in the near future. This model was also assessed under financial aspects, showing promising results in terms of financial returns.

Keywords: Stock Markets, Technical Analysis, Machine Learning, Deep Learning, Long Short-Term Memory, Artificial Neural Networks, Recurrent Neural Networks.

Lista de Figuras

2.1	Indicador técnico: MACD - <i>Moving average convergence/divergence</i> [Wikipedia, 2004]	7
2.2	Indicador técnico: RSI - <i>Relative strength index</i> [Wikipedia, 2004]	8
2.3	Redes neurais <i>Feed-forward</i>	9
2.4	Redes neurais recorrentes	10
2.5	Redes Long short-term memory [Greff et al., 2015]	11
4.1	Metodologia de previsão baseada em análise técnica	17
4.2	<i>Candlestick</i> [Bússola do Investidor, 2007]	19
4.3	Gráfico de <i>Candlesticks</i> [Bússola do Investidor, 2007]	20
5.1	Evolução do preço de BOVA11	30
5.2	Evolução do preço de BBDC4	31
5.3	Evolução do preço de CIEL3	31
5.4	Evolução do preço de ITUB4	32
5.5	Evolução do preço de PETR4	32
5.6	Distribuição das classes por ativo no treino	33
5.7	Distribuição das classes por ativo no teste	33
5.8	Taxa de acerto por ativos	35
5.9	Coeficiente de variação do acerto	36
5.10	Diferença estatística - Kruskal-Wallis	37
5.11	Retornos financeiros por ativo	38
5.12	Retornos financeiros médios por ativo	38
5.13	<i>Max Drawdown</i>	39

Lista de Tabelas

4.1	Ativos usados para experimentos	19
4.2	Possíveis saídas da rede	22
5.1	Ativos utilizados e sua variação de preço	30
5.2	Métricas de avaliação	35
A.1	Indicadores técnicos gerados pela TA-Lib [TicTacTec, 1999]	55

Sumário

Agradecimentos	vii
Resumo	ix
Abstract	xi
Lista de Figuras	xiii
Lista de Tabelas	xv
1 Introdução	1
1.1 Motivação	3
1.2 Objetivos	3
1.2.1 Objetivos específicos	3
1.3 Contribuições Esperadas	4
1.4 Organização do Trabalho	4
2 Fundamentação teórica	5
2.1 Introdução ao Mercado Financeiro	5
2.1.1 Análise técnica	7
2.2 Redes neurais artificiais	8
2.2.1 Redes neurais recorrentes	9
2.2.2 Redes Long-Short Term Memory	10
3 Trabalhos relacionados	13
4 Metodologia	17
4.1 Definição do problema	17
4.2 Base de dados	18
4.3 Pré-processamento e transformação dos dados	20

4.3.1	Suavização da série temporal	20
4.3.2	Indicadores técnicos	21
4.3.3	Normalização	21
4.3.4	Janelas deslizantes	22
4.3.5	Classes	22
4.4	Rede neural artificial	23
4.5	Análise de experimentos	24
4.5.1	Testes estatísticos	25
4.6	Análise financeira	26
5	Experimentos	29
5.1	Caracterização e análise dos dados	29
5.2	Resultados experimentais	34
6	Conclusão	41
6.1	Contribuições realizadas	42
6.2	Trabalhos futuros	42
	Referências Bibliográficas	45
A	Indicadores técnicos	51

Capítulo 1

Introdução

O mercado de ações é uma parte importante de qualquer economia, e devido a isso o seu entendimento é constante alvo de vários estudos. Investidores, economistas e pesquisadores de diversas áreas procuram modelos e informações que possam ajudá-los a entender e possivelmente prever o comportamento do mercado.

No entanto, dada a complexidade e dinamismo inatos ao mercado, as tarefas de prevê-lo ou modelá-lo se mostram incrivelmente difíceis de se alcançar, pois existe um número imenso de variáveis assim como diferentes fontes e tipos de informação. A relação de sinal e ruído é muito baixa, causando com que os modelos encontrados na literatura falhem em prover previsões precisas de maneira generalizada.

Ainda sim, o movimento de preços de ativos é alvo de estudo de diversas disciplinas como economia, estatística, física ou ciência da computação. O intuito é ser capaz de prever o preço futuro de um ativo de forma a obter lucro através de negociações explorando uma gama variada de abordagens.

Existem diversos métodos de analisar o comportamento de um ativo, sendo dois dos mais clássicos e populares a análise técnica, que é um conjunto de métodos matemáticos que se utilizam do histórico de preços e volume negociado para prever tendências futuras e a análise fundamentalista que se baseia nos dados econômicos das empresas ou setores em si.

Além disso, existem aspectos externos que podem alterar bruscamente o comportamento do mercado, como fatores macro-econômicos, políticos ou sociais. Notícias como conflitos políticos ou desastres ambientais podem mudar abruptamente a direção do movimento de ativos específicos ou do mercado como um todo.

Desta forma, muitos investidores tendem a escolher um método com o qual se sentem mais confortáveis, ou que por algum motivo acreditam que é mais eficiente. Uma abordagem bastante difundida é utilizar-se de algoritmos de inteligência computacional,

e através de uma ou mais das fontes de dados citadas, criar modelos capazes de prever tendências no preço de ações do mercado.

Este trabalho elege a análise técnica juntamente com Aprendizado de Máquina para a tarefa de prever movimentos de preço em ativos da Bolsa de Valores de São Paulo (BM&FBovespa).

A proposta é usar dados históricos de preço e volume, juntamente a indicadores técnicos derivados desses dados, e através de aprendizado supervisionado ser capaz de determinar o comportamento das séries temporais financeiras e classificá-las por meio de redes neurais.

Por se tratar de um problema caracterizado por uma série temporal, a ideia é que redes neurais recorrentes possam ser mais apropriadas para este tipo de problema do que outros algoritmos em que não haja memória de curto prazo.

Sendo assim, além do que é aprendido em treinamento estas redes também levam em consideração os acontecimentos recentes, como por exemplo, as mudanças de preço em períodos recentes para prever o preço no período seguinte.

O algoritmo escolhido é baseado em redes *Long Short-Term Memory* (LSTM), que são um tipo de rede neural recorrente, e que provaram ser bem sucedidas em uma gama de diferentes problemas graças a sua capacidade de distinguir entre ocorrências recentes e distantes, dando diferentes pesos para cada e sendo capaz de ignorar memórias que possam ser consideradas irrelevantes para prever a próxima saída. Desta forma, elas tem maior capacidade de lidar com sequências de dados longas quando comparadas a outras redes neurais recorrentes.

O intuito deste projeto é estudar a aplicabilidade de redes neurais recorrentes, em particular as redes LSTM, no problema de previsão de tendências em preços no mercado de ações. Estudar o desempenho de tais redes em termos de precisão, acurácia e outras métricas de previsão utilizando dados reais e analisar se elas apresentam qualquer tipo de melhora em comparação a outros algoritmos mais tradicionais de Aprendizado de Máquina.

Além disso, também validar o modelo proposto em relação ao seu desempenho em termos financeiros, através de comparações com estratégias de investimento mais simples, contudo efetivas, observando os retornos obtidos e também lucro por operação.

Ao final deste trabalho, objetiva-se por uma caracterização desse comportamento que seja coerente com a realidade e que possa ser observada em dados futuros a fim de ser capaz de prever as tendências de preço para ativos da bolsa de valores com a maior precisão possível.

1.1 Motivação

A motivação por trás desse trabalho se dá pelo estudo, através de métodos computacionais, de uma área que é de suma importância para qualquer economia.

Existem vários trabalhos que procuram prever o comportamento de bolsas de valores, com variados índices de sucesso, contudo esse ainda é considerado um desafio em aberto.

Esse trabalho parte da premissa de que certos métodos de inteligência computacional, em especial *deep learning* e redes neurais recorrentes, se mostram promissores na tarefa de aprendizado do funcionamento da bolsa de valores.

A abordagem proposta nesse trabalho ainda não foi explorada extensivamente na literatura para este tipo de problema especificamente, e a hipótese levantada é que o uso de redes recorrentes pode auxiliar na busca por melhores resultados.

1.2 Objetivos

Esse trabalho tem como objetivo central o estudo de técnicas de inteligência computacional para entendimento e previsão de tendências de preços no mercado financeiro, mais especificamente na bolsa de valores. Em especial, o estudo de redes recorrentes e quais benefícios as suas características podem trazer para este problema.

O intuito é utilizar-se de dados de preço para fazer essas previsões por meio de aprendizado de máquina, procurando aprender e evidenciar padrões e tendências no comportamento de preços de ativos.

1.2.1 Objetivos específicos

Os objetivos específicos deste trabalho são os seguintes:

- Coletar e caracterizar dados de preço relacionadas a ativos da bolsa de valores.
- Propor um modelo de previsão a partir de dados de preço utilizando técnicas de aprendizado de máquina, em especial redes neurais recorrentes.
- Avaliar o desempenho do modelo usando redes recorrentes, comparando com outros métodos clássicos de aprendizado de máquina em termos de métricas de acerto.
- Analisar também o desempenho do modelo em termos de retornos financeiros.

1.3 Contribuições Esperadas

As principais contribuições previstas para este trabalho são as seguintes:

- Um novo modelo de previsão de tendências de preço para mercados de ações utilizando técnicas baseadas em *deep learning*.
- A validação do modelo utilizando dados reais da Bolsa de Valores de São Paulo (BM&FBovespa).
- Avaliação do modelo por meio de comparações e análises em relação a outros algoritmos de Aprendizado de Máquina e *baselines* clássicos de *algotrading*.

1.4 Organização do Trabalho

O restante da dissertação é organizado da seguinte maneira: O Capítulo 2 apresenta uma visão geral dos conceitos teóricos em quais este trabalho se baseia, tanto no contexto do mercado financeiro quanto em Aprendizado de Máquina; No Capítulo 3 são mencionados outros trabalhos encontrados na literatura que também procuram lidar com o mesmo problema e possuem características relacionadas com o que é apresentado neste trabalho, além disso também ressalta as novidades que este estudo pretende trazer; Já o Capítulo 4 detalha o modelo proposto nesta dissertação, e o Capítulo 5 apresenta e discute os resultados experimentais; E por fim, no Capítulo 6 são apresentadas as conclusões do trabalho.

Capítulo 2

Fundamentação teórica

Este capítulo apresenta uma visão geral dos conceitos que são fundamentais para este trabalho, tanto em relação a conceitos básicos em relação ao mercado financeiro e finanças computacionais (Seção 2.1), quanto aos conceitos de aprendizado de máquina, mais especificamente redes neurais (Seção 2.2), que serão base para o modelo proposto.

2.1 Introdução ao Mercado Financeiro

O mercado financeiro é o local onde podem ser negociados, comprados ou vendidos, bens como valores mobiliários, mercadorias e câmbio. Mercados são considerados como parte vital de qualquer economia, pois quanto mais ativo, mais se traduz em oportunidades para que pessoas e empresas apliquem seus recursos e contribuam para o aquecimento da economia. Desta forma, também são considerados um termômetro da saúde da economia.

É um ambiente onde investidores podem negociar tais bens entre si. O princípio é simples, tentar comprar quando acredita-se que o ativo está sub-precificado ou em que há a expectativa de que vá subir de preço no futuro, e vender quando acredita-se que o preço irá diminuir, de forma a obter lucro. No entanto, realizar essas previsões é um desafio gigantesco pois existem inúmeros fatores que podem influenciar no valor de um ativo.

No Brasil temos a Bolsa de Valores de São Paulo (BM&F Bovespa), que é responsável por gerir e administrar negociações de títulos, valores mobiliários e contratos derivativos no país, realizando serviços de registro, compensação e liquidação das operações realizadas.

Dentre os ativos que podem ser negociados, destacam-se as ações, que são títulos de empresas e correspondem à menor parcela de seu valor. As ações representam o

direito à propriedade e lucros da empresa.

Esses títulos são emitidos quando uma empresa toma a decisão de abrir seu capital para o público, e ser negociado na bolsa de valores. Seu valor é determinado pela relação de oferta e demanda, e pode ser considerado um reflexo das condições estruturais, de mercado e financeiras da empresa.

Existem agentes tentando comprar ou vender ativos a todo momento, e tendo suas decisões influenciadas pelos mais diversos fatores, desde análises bem fundamentadas até aspectos puramente psicológicos ou especulativos. Isso causa uma grande volatilidade na variação dos preços.

Podemos observar as variações de preço sobre a variação do tempo em forma de uma série temporal. Levando em conta a volatilidade, e certa aleatoriedade no movimento dessa série, podemos inferir que a relação de sinal e ruído nessa série é baixa.

Em relação às previsões no mercado financeiro, dada a sua complexidade e dinamismo inatos, existe um constante debate quanto a possibilidade de prever mudanças de preços em ações. Fama & Malkiel [1970] introduziu a hipótese do Mercado Eficiente que diz que o preço atual de um ativo sempre reflete toda a informação previamente existente instantaneamente, ou seja, não é possível utilizar nenhuma informação conhecida para prever preços futuro.

Em conjunto a essa, existe também a hipótese do passeio aleatório [Malkiel, 1973] que alega que o preço de uma ação varia independentemente do seu histórico, em outras palavras, o preço de amanhã irá ser influenciado apenas pela informação de amanhã, independente do preço de hoje.

Essas duas hipóteses juntas determinam que não existem meios de prever precisamente o preço de uma ação, e ainda existem experimentos que mostram que uma estratégia de investimento utilizando um agente tomando decisões completamente aleatórias pode por vezes superar alguns dos métodos mais tradicionais de investimento como “Convergência e Divergência de Médias Móveis” (*Moving Average Convergence / Divergence*) e “Índice de Força Relativa” (*Relative Strength Index*) [Biondo et al., 2013].

Por outro lado, existem diversos outros autores que alegam por meio de experimentos, que de fato, variações de preços de ações podem sim ser previstas até certo nível [Lo & MacKinlay, 1999]. E uma variedade de métodos para previsão e modelagem do comportamento de ações são objeto de estudo de várias disciplinas, sendo importante notar que em 2012 era estimado que aproximadamente 85% das negociações de ações feitas nas bolsas de valores dos Estados Unidos eram feitas através de algoritmos [Glantz & Kissell, 2013].


2.1.1 Análise técnica

Um dos métodos mais populares para tomada de decisões de investimento na bolsa de valores é a análise técnica, que é definida por Kirkpatrick & Dahlquist [2006] como uma metodologia de previsão de tendências baseada apenas em dados históricos do mercado, principalmente de preço e volume. A análise técnica também se baseia nas seguintes suposições:

- Preços de ativos são definidos unicamente pela relação de oferta e demanda.
- Preços de ativos variam seguindo tendências.
- Alterações de oferta e demanda causam reversões nas tendências.
- Alterações de oferta e demanda podem ser identificadas em gráficos.
- Padrões em gráficos tendem a se repetir.

Ou seja, a análise técnica ignora quaisquer fatores externos, sejam eles políticos, sociais ou macro-econômicos.

Figura 2.1. Indicador técnico: MACD - *Moving average convergence/divergence* [Wikipedia, 2004]



Indicadores técnicos são cálculos matemáticos a partir de dados históricos de preço e volume de ativos que buscam prever tendências em variações de preços.

Figura 2.2. Indicador técnico: RSI - *Relative strength index* [Wikipedia, 2004]



Exemplos de indicadores técnicos são como os presentes nas Figuras 2.1 e 2.2. Convergência e Divergência de Médias Móveis (MACD) são uma forma de identificar tendências através da combinação de médias móveis exponenciais de diferentes períodos, já o Índice de Força Relativa (RSI) determina a intensidade da tendência baseado em um cálculo dos ganhos recentes sobre as perdas recentes de um período arbitrário.

Existe uma enorme quantidade de indicadores e com diferentes intuitos, como medir a intensidade de uma tendência, possíveis reversões ou a direção mais provável do movimento de preço. Sua eficiência em geral é medida por meio de *backtesting*, que é a prática de validação usando dados passados.

2.2 Redes neurais artificiais

Redes neurais artificiais foram idealizadas como uma forma de criar uma representação matemática análoga ao que se acreditava ser a estrutura de um cérebro biológico. De forma que a estrutura possui unidades que são equivalentes a neurônios e as reações químicas responsáveis por transportar informações entre os neurônios são representadas por funções de ativação.

Cada unidade (ou neurônio) de uma rede neural possui um determinado valor, conhecido como peso. E esse peso é atribuído através de um processo conhecido como treinamento, onde vários exemplos são abastecidos à rede e esta “aprende” os melhores




Figura 2.3. Redes neurais *Feed-forward*

pesos em um processo de otimização, tentando ao máximo generalizar e errar o menos possível quando exposta a exemplos desconhecidos.

Inicialmente, os dados a serem computados são passados às unidades de entrada, os valores são multiplicados pelos pesos destas e passados em sequência às unidades com as quais possuem conexões diretas.

Redes neurais normalmente são organizadas em camadas, com cada camada possuindo uma ou mais unidades, e as saídas das unidades são combinadas, utilizando a função de ativação, e usadas como entradas das unidades da camada seguinte.

Tradicionalmente, redes neurais possuem um fluxo de informação unidirecional, não existindo nenhum tipo de ciclo, ou seja, um grafo acíclico como pode ser observado na Figura 2.3. Esse tipo de arquitetura é denominado como *feed-forward*.

Uma rede neural deste tipo é uma função de sua entrada, não possuindo nenhum tipo de estado interno além dos pesos em si.

2.2.1 Redes neurais recorrentes

Diferentemente das redes neurais *feed-forward*, redes neurais recorrentes possuem ciclos entre suas unidades. Em outras palavras, unidades podem ter conexões com unidades de camadas anteriores, ou da mesma camada (Figura 2.4).

Desta forma, a informação não flui em um único sentido, e a saída da rede não depende mais apenas da entrada corrente, mas também das entradas anteriores. O efeito prático disto é a existência de memória de curto prazo na rede.

Se consideramos o aprendizado por treinamento uma espécie de memória de longo prazo, então adicionalmente à nova capacidade manter uma memória recente, redes neurais recorrentes podem criar modelos muito mais complexos, que apesar de serem




Figura 2.4. Redes neurais recorrentes

de compreensão mais difícil apresentam capacidade de resolver uma gama maior de problemas.

Mesmo com redes neurais *feed-forward* é possível ter um efeito similar ao de memória, como por exemplo, adicionando à entrada dados de entradas anteriores, multiplicando a dimensionalidade, ou mesmo adicionando parâmetros com algum aspecto temporal. Mas esses casos podem acabar causando o problema de maldição da dimensionalidade (*curse of dimensionality*) onde a entrada fica muito complexa e dificulta o aprendizado e generalização.

Contudo, mesmo redes neurais recorrentes podem apresentar desafios no processo de treinamento. Ainda que na teoria sejam capazes de lidar com dependências de longo termo (longas sequências), Bengio et al. [1994] mostra através de experimentos que na prática isso muitas vezes não é possível, pois em métodos de treinamento baseados em gradientes a informação de erro desaparece.

2.2.2 Redes Long-Short Term Memory

Redes *Long Short-Term Memory* (LSTM) (Figura 2.5), que são o modelo de escolha deste trabalho, são um modelo recorrente e profundo de redes neurais. LSTM foram introduzidas por Hochreiter & Schmidhuber [1997] e sua motivação foi em oferecer um desempenho melhor por resolver o problema de desaparecimento de gradiente que redes neurais recorrentes naturalmente sofrem quando lidam com grandes sequências de dados.

Elas o fazem ao manter o fluxo do erro constante através de unidades especiais chamadas “portões” (*gates*), que permitem ajustes de pesos da mesma forma que o truncamento da sequência quando a informação não é necessária, simbolizando um esquecimento.

Esse tipo de rede tem sido amplamente usado e sido capaz de alcançar alguns dos

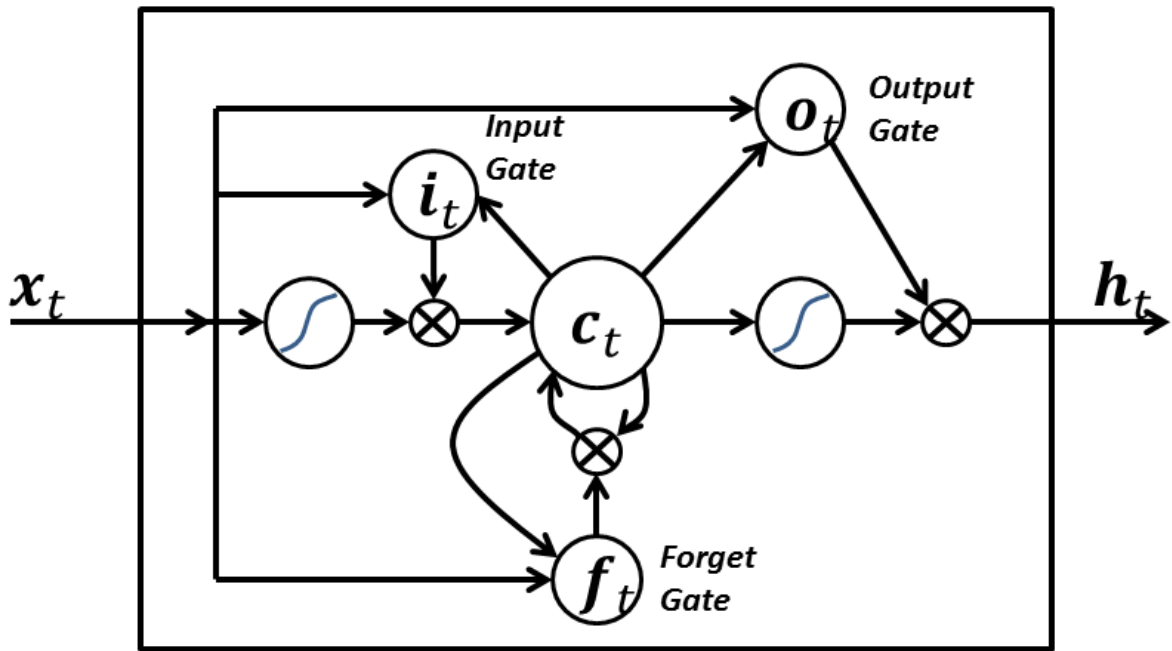


Figura 2.5. Redes Long short-term memory [Greff et al., 2015]

melhores resultados quando colocados em comparação com outros métodos [Graves, 2012]. Este fato é observado especialmente no campo de Processamento de Linguagem Natural, e em reconhecimento de caligrafia é considerada o estado-da-arte [Graves et al., 2009].

Desde a sua concepção, este método foi ramificado em diversas variações. Entretanto, quando avaliadas em relação à original por Greff et al. [2015], nenhuma foi capaz de apresentar nenhuma melhoria considerável em termos de resultados.

Capítulo 3

Trabalhos relacionados

Existem diversos estudos sobre o uso de inteligência computacional para predição de preços de ativos do mercado financeiro, usando os mais variados algoritmos como Algoritmos Genéticos [Allen & Karjalainen, 1999] e Máquina de Vetor de Suporte (SVM) [Jae Kim, 2003], além de redes neurais que serão objeto de estudo neste trabalho. Em Melo [2012] é realizado um levantamento de diferentes técnicas desenvolvidas recentemente para previsão de séries temporais do mercado financeiro, como redes neurais, modelagem de componentes, sistemas especialistas e multiagentes e análise textual de notícias, e também faz uma análise acerca de algumas pesquisas na área, além de propor uma abordagem diferente para a previsão com base em inteligência coletiva.

Pommeranzenbaum [2014] propõe um modelo de predição de valores nas séries de preço do índice IBovespa utilizando dados históricos de preço de diversas bolsas de valores pelo mundo como treino, e através de Redes Neurais Artificiais (RNAs) determinar os preços futuros e por meio de um ambiente simulado validar diferentes estratégias de mercado em cima de tais previsões.

Por se tratar de uma série temporal, a previsão de preços de ativos motivou estudos usando redes neurais recorrentes em diferentes abordagens, como a partir dos próprios dados de preço [Kamijo & Tanigawa, 1990] ou de indicadores técnicos [Wang & Leu, 1996].

Em Bebarta et al. [2015] é apresentado um modelo de redes neurais recorrentes utilizando indicadores técnicos para prever preços futuros no mercado de ações indiano, e os resultados são melhores que os *baselines* na maioria dos experimentos. Também no mercado ações indiano, Rather et al. [2015] propõe um novo modelo baseado em redes neurais recorrentes para determinar preços futuros e compara os resultados com modelos lineares, obtendo melhores resultados.

O uso de aprendizado profundo (*deep learning*) pode ser bastante efetivo para

classificar dados que são de difícil representação, como o texto de notícias, e Yoshihara et al. [2014] mostra como isso pode colaborar na previsão de preços no mercado financeiro através de redes neurais recorrentes.

Outros trabalhos relacionados ao uso de aprendizado profundo em mercados de ações podem ser vistos em Batres-Estrada [2015] onde um estudo é feito sobre o uso de *Deep Belief Network* (DBN), que são compostas de Máquinas Restritas de Boltzmann, acoplado a um Perceptron Multinível (MLP) e usando retornos (variação no preço) de longo prazo para detectar/prever retornos acima da mediana a cada dia. Sharang & Rao [2015] também faz uso de DBN, mas usando o histórico de preços juntamente a indicadores técnicos, em uma abordagem similar ao deste projeto. Ambos estes trabalhos apresentaram resultados melhores em comparação aos *baselines* escolhidos. Da mesma forma que Heaton et al. [2016] onde um estudo a respeito de métodos de aprendizado profundo aplicado a finanças é feito e seus benefícios são discutidos.

Apesar da análise técnica ser possivelmente o método mais popular de previsão entre investidores, é possível aprimorar a capacidade de previsão de um modelo incluindo dados de outro tipo de análise, como a fundamentalista [Iuhasz et al., 2012; Adebisi Ayodele A., 2012].

Em Jaybhay et al. [2012] é proposto um modelo que procura prever o preço de fechamento diário do índice combinando dados de preço e notícias em uma rede neural *feed-forward* e a partir disso obtendo resultados com alta precisão e revogação. Já Machado et al. [2015] apresenta um outro estudo que utiliza dados históricos de preço juntamente a dados da *Web* e, baseado na teoria de Ondas de Elliott, propõe diversas estratégias de negociação e mostra que o uso de indicadores distintos pode minimizar perdas e aumentar o número de gatilhos que geram lucro.

Para previsões em preços de ações, dado ao notável desempenho que redes LSTM exibem em processamento de linguagem natural, estas redes na maioria dos casos são usadas juntamente a texto de notícias como entrada para prever tendências de preço. Assim como Akita et al. [2016] utiliza dados numéricos de preço além de dados de notícias para realizar previsões na bolsa de valores japonesa utilizando redes LSTM e compara os resultados com outros algoritmos de aprendizado de máquina, MLP, SVM e uma arquitetura simples de redes recorrentes, e obtém resultados superiores na maior parte dos casos.

Entretanto, também existem alguns trabalhos utilizando os próprios dados de preço para prever variações futuras. Chen et al. [2015] emprega dados históricos de preço juntamente a dados de índices de ações para prever se o preço de uma ação vai subir, descer ou permanecer o mesmo em determinado dia.

Luca Di Persio [2016] compara os desempenhos de LSTM e MLP com o seu

próprio método que é proposto baseando em uma combinação de *wavelets* e redes neurais convolutivas que é capaz de superar ambos, contudo apresentado resultados similares aos da rede LSTM.

Neste projeto propomos um método baseado em redes LSTM para prever movimentos de preço com dados de entrada que não são baseados em texto, algo que não tem sido amplamente explorado ainda. O plano inicial é utilizar uma grande variedade de indicadores técnicos para tais previsões, sendo que a intenção é avaliar o uso deste método que é algo comumente usado em estratégias de investimento. Além disso, pretendemos testar a hipótese que a capacidade de memória recente pode apresentar resultados superiores em relação a métodos de Aprendizado de Máquina sem memória.

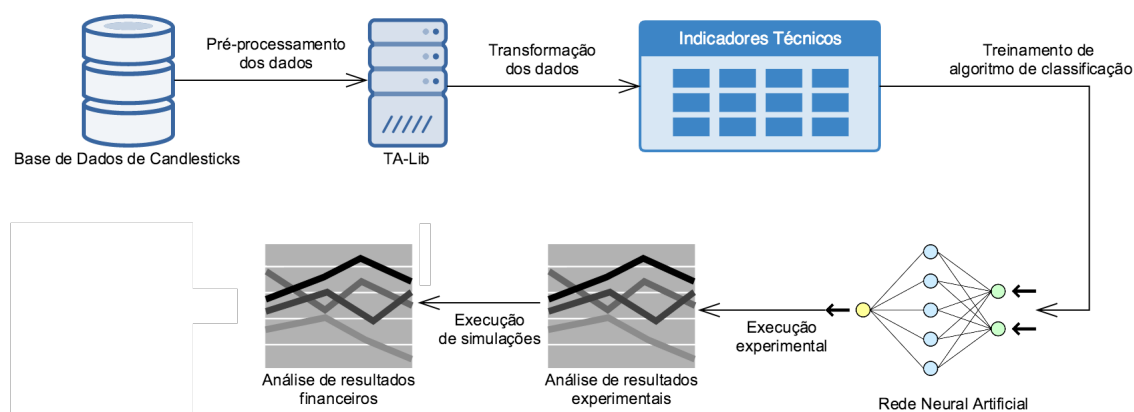
Capítulo 4

Metodologia

Este capítulo descreve o problema a ser tratado neste trabalho (Seção 4.1), e em conjunto a metodologia proposta para este fim que é ilustrada na Figura 4.1.

O método proposto será validado em experimentos usando dados de diferentes ativos da bolsa de valores de forma a averiguar se ele pode ser generalizado ou caso se comporte melhor em ativos que respeitem determinado padrão.

Figura 4.1. Metodologia de previsão baseada em análise técnica



4.1 Definição do problema

O problema base deste trabalho em termos gerais é a predição de variações de preço em ativos da bolsa de valores. De uma forma mais específica, o problema é utilizar

análise técnica baseada em dados históricos de preço e volume destes ativos para prever movimentações de preço por meio de redes LSTM.

Este um problema de aprendizado, e tem como primeiro desafio, após a obtenção e pré-processamento dos dados, o aprendizado de *features*, ou seja, formas eficientes de representar as entradas. Em relação à modelagem, é um problema de rotulação de sequências temporais, no caso uma sequência de informações de preço e indicadores técnicos.

Um modelo de redes neurais LSTM foi proposto, e a partir de dados históricos de preço de um determinado ativo (X), o modelo irá ser treinado para determinar se o preço de tal ativo irá subir ou não em um momento seguinte ($y \in \{0, 1\}$).

Os experimentos previstos nesse trabalho incluem as validações costumeiras em algoritmos de aprendizado de máquina, como executar os algoritmos contra dados de teste e coletar métricas como precisão, revocação e medida F1. Também serão feitas análises em torno de retorno financeiro.

Dado isso, esse trabalho parte da hipótese de que é possível através de uma rede neural aprender os padrões e tendências (e reversões de tendências) que a análise técnica se dispõe a identificar.

A Figura 4.1 ilustra a metodologia a ser usada nesse problema e as seções seguintes detalham os seus itens.

4.2 Base de dados

Foram coletados dados de preço de ativos negociados na BM&F Bovespa. A granularidade desses dados é de 15 minutos, ou seja, a base de dados possui dados de preços consolidados a cada 15 minutos, desde a abertura de negociações diária, até o fechamento, em um período que corresponde de 10:00 às 18:00 horas.

A tabela 4.1 lista os ativos escolhidos para os experimentos desta pesquisa. Foram escolhidos ativos dentre os que compõe o índice IBovespa, que são os ativos que maior volume de negociação na bolsa, logo apresentando maior liquidez. São quatro ativos de três diferentes setores, foram escolhidos duas ações de bancos (ITUB4 e BBDC4) para também avaliar se existem padrões de comportamento em ativos que apresentam alta correlação entre si. Juntamente a estes ativos, também foram executados experimentos utilizando as ações das empresas Cielo (CIEL3) e Petrobrás (PETR4).

E por fim, também fez parte dos experimentos o ativo BOVA11, que é um *exchange traded fund* (ETF). Um ETF é uma unidade negociável na bolsa de valores da mesma forma que uma ação, contudo rastreando o comportamento de um índice.

Nesse caso, o índice em questão é o da Bovespa (IBovespa).

Foram separados dados correspondentes ao ano de 2014. Esta janela de dados foi escolhida pois no momento de em que esta pesquisa se iniciou, era o período de um ano completo mais recente disponível.

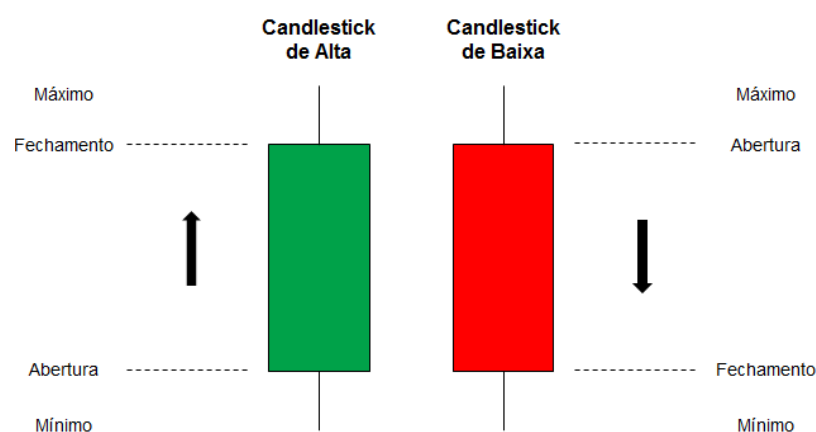
Tabela 4.1. Ativos usados para experimentos

Símbolo	Nome
BOVA11	ETF que segue o índice Bovespa
BBDC4	Banco Bradesco S.A.
CIEL3	Cielo S.A.
ITUB4	Itaú Unibanco Holding S.A.
PETR4	Petróleo Brasileiro S.A. — Petrobras

Os dados utilizados para esta parte da pesquisa são as informações de preço (abertura, fechamento, máximo, mínimo) consolidadas de um determinado ativo, também referidas como *candles*. Em outras palavras, na granularidade escolhida (p. ex., 15 minutos), são o valor que do preço no início do período, juntamente ao valor no final do período além dos valores máximo e mínimo que o preço atingiu dentro daquele intervalo.

A Figura 4.2 detalha o formato de um *candle* individualmente enquanto a Figura 4.3 mostra um gráfico de *candles* de um determinado ativo.

Figura 4.2. *Candlestick* [Bússola do Investidor, 2007]



Além dos dados de preço também serão coletados dados de volume de negociações, também com granularidade de 15 minutos.

Figura 4.3. Gráfico de *Candlesticks* [Bússola do Investidor, 2007]

A partir desses dados é feito um pré-processamento, e é gerado um conjunto de indicadores técnicos que juntamente com os dados originais serão usados como entrada para a rede neural.

4.3 Pré-processamento e transformação dos dados

4.3.1 Suavização da série temporal

Séries temporais de preços de ações são sujeitas a uma quantidade considerável de ruído e variação aleatória, o que dificulta a tarefa de previsão.

Uma maneira de reduzir esse problema e melhorar a capacidade de previsão é através de suavização exponencial, que pode ser alcançada usando médias móveis exponencialmente ponderadas (*exponentially weighted moving averages*) (4.1) conforme indicado por Khaidem et al. [2016].

Essa equação determina um novo valor (z_i) para cada ponto da série temporal (x_i), e usa uma variável λ (com valores entre zero e um) definida arbitrariamente, que é conhecida como parâmetro de suavização. Essa variável será utilizada para ponderar

cada ponto anterior na série temporal $((1 - \lambda)\lambda^1, (1 - \lambda)\lambda^2, \dots, (1 - \lambda)\lambda^n)$.

$$z_i = \lambda \bar{x}_i + (1 - \lambda)z_{i-1} \quad (4.1)$$

4.3.2 Indicadores técnicos

A partir dos dados de preço são gerados um conjunto de indicadores técnicos para cada instância da entrada através da ferramenta *TA-Lib*¹.

Essa ferramenta é capaz de gerar 138 diferentes indicadores de análise técnica que podem ser observados na Tabela A.1. Estes serão utilizados como entrada para o algoritmo de aprendizado de máquina responsável por prever as variações de preço.

Esses indicadores expressam diversas características da série de preços, como força e direção de tendências, medidas de risco e possíveis reversões. Estas informações serão utilizadas para ajudar a prever se haverá ou não alta em 15 minutos no futuro.

4.3.3 Normalização

Antes de alimentar a rede neural com os dados, é necessário normalizá-los de forma a facilitar a convergência no treinamento e generalização na previsão. Para os dados de preço (máximo, mínimo, abertura, fechamento) o método de normalização escolhido foi a diferença entre o *log* do preço atual em relação ao anterior, conhecido como “log-retorno”. A transformação é feita subtraindo o *log* do preço atual (p_i) pelo *log* do preço anterior (p_{i-1}), descrita em (4.2):

$$\log(p_i) - \log(p_{i-1}) \quad (4.2)$$

Este método de normalização é defendido por diversos autores como causa de melhores resultados já que nesse caso os valores absolutos de preço, que podem variar bastante no longo prazo, são trocados pela variação de preço pelo tempo, que são padrões mais prováveis de se repetir.

Para os outros atributos da entrada que não são dados de preço a normalização se dá por converter cada valor para seu valor padronizado (*z-score*) (4.3), assim colocando todo os dados na mesma escala ao subtrai-los pela média da série e em seguida dividir pelo desvio padrão da mesma.

$$z = \frac{x - \mu}{\sigma} \quad (4.3)$$

¹<http://ta-lib.org>

4.3.4 Janelas deslizantes

Séries temporais de preços de ações mudam constantemente seu comportamento e são influenciadas por muitos fatores externos de toda espécie (políticos, locais, ou macroeconômicos), e por isso modelos capazes de generalizar no longo prazo são algo distante de se conseguir, logo prima-se pelo uso de apenas dados recentes.

Para este trabalho utilizamos o conceito de janela deslizante, no qual a massa de dados de treinamento, validação e teste se move conforme o tempo.

Mais especificamente, um modelo de predição é gerado a cada novo dia de negociação, treinado e validado usando dados dos dias anteriores e testado sob os dados do dia que está por vir.

Para validação são utilizados os dez dias de negociação anteriores, por volta de 320 *candles*, e para treinamento os dois meses de negociação anteriores a estes, totalizando cerca de 1280 *candles*.

Os experimentos de teste foram executados nos últimos vinte dias de negociação de 2014, em um total de aproximadamente 640 *candles*, contemplando o mês de Dezembro e o final do mês de Novembro.

A rede LSTM tem como entrada não apenas a instância de dados atual, mas também as anteriores. Para este modelos são utilizados as nove entradas anteriores, mais a atual (totalizando dez) para prever a seguinte.

Estes hiper-parâmetros foram definidos através de testes empíricos e escolhidos avaliando a qualidade dos resultados e custo de execução.

4.3.5 Classes

À cada uma das entradas da base de dados, uma classe binária (y) será atribuída, sendo que o valor “1” indicará que o preço irá subir no momento seguinte e “0” que não irá. Portanto, dado que i é o momento atual e j o seguinte, logo $j = i + \text{intervalo}$, sendo que para este projeto *intervalo* é equivalente a 15 minutos. Para o caso de saída “1”, uma operação de “compra” será executada em i e uma de venda em j .

Tabela 4.2. Possíveis saídas da rede

Saída (y)	Descrição	Ação
1	O preço do ativo irá subir	Ativa o gatilho para operação de compra
0	O preço não irá subir	Nenhuma

Para atribuir as classes, a política usada para determinar o valor é baseada no preço de fechamento do momento seguinte será maior (classe “1”) ou não (classe “0”)

que o preço de fechamento do momento atual:

$$y = \begin{cases} 1 & \text{se } fechamento_j > fechamento_i \\ 0 & \text{se } fechamento_j \leq fechamento_i \end{cases} \quad (4.4)$$

4.4 Rede neural artificial

O algoritmo de previsão utilizado nessa pesquisa será uma rede neural artificial que segue um modelo de *deep learning*, onde existem múltiplas camadas ocultas e a rede é capaz de lidar com entradas mais complexas e aprender novas e melhores representações (*feature learning*).

Essa rede buscará prever se haverá, ou não, variação positiva de preço no próximo período dados os dados do período atual e dos mais recentes. E as saídas poderão ser conforme o descrito na Tabela 4.2.

O algoritmo de rede neural utilizada foi o de redes LSTM, estas redes tem a capacidade de lidar com sequências temporais para efetuar previsões. Por se tratarem de um modelo de aprendizado profundo, também são capazes de ter bom desempenho com entradas de alta dimensão.

Nossa intenção é fazer com que o algoritmo seja capaz de aprender quais informações são mais relevantes daquele conjunto de indicadores técnicos, e usá-la posteriormente para melhorar a capacidade de previsão.

O modelo de rede é composto por uma camada LSTM que recebe dez entradas de 180 atributos cada (10 x 180), reduz a dimensão usando uma ativação *tanh* para 20 conexões que são passadas à camada de saída, que retorna valores por uma função *sigmoid*.

Redes recorrentes lidam com mais de uma entrada por vez, e no caso do modelo proposto serão dez entradas por vez, ou seja, sendo que X é uma tupla com os 180 diferentes atributos da entrada ($X = (x_1, x_2, \dots, x_{180})$), então o que será fornecido à rede é um conjunto das dez últimas instâncias de X ($X' = \{X_{t-9}, X_{t-8}, \dots, X_{t-1}, X_t\}$).

Foram executados experimentos utilizando métodos de redução de dimensionalidade como *Principal Component Analysis* (PCA) e *AutoEncoder*, entretanto não foram observadas diferenças significativas na qualidade dos resultados e, por este motivo, foram descartados.

Entre as camadas haverá uma técnica de regularização conhecida como *dropout*, que faz com que neurônios sejam excluídos aleatoriamente do processo de treinamento para evitar sobreadaptação (*overfitting*) no modelo de previsão, aumentando a capacidade de generalização.

Como saída a rede retornará valores em zero e um, que serão arredondados para a classe mais próxima. Para isso será utilizada a função *sigmoid* (4.5).

$$S(t) = \frac{1}{1 + e^{-t}} \quad (4.5)$$

A rede foi treinada utilizando o método de otimização *Adam*, que é um método baseado em gradiente com taxa de aprendizado adaptativa, e buscando minimizar a entropia cruzada da rede.

O modelo foi projetado utilizando a implementação de redes LSTM presente na biblioteca *TensorFlow*² sendo utilizada sob a interface da biblioteca *Keras*³.

4.5 Análise de experimentos

Os experimentos teóricos previstos nesse projeto consistem na execução de *backtests* para o modelo construído usando dados de diferentes ativos. *Backtesting* é o processo de validar uma estratégia de investimento usando dados passados. Nesse caso, parte da base de dados será separada a fim de executar esses testes e coletar as métricas.

A partir desses experimentos serão coletadas métricas relativas à capacidade de acerto da rede (4.6), como precisão (4.7), revocação (4.8) e medida F1 (4.9), de forma a avaliar a qualidade do modelo.

Essas métricas são calculadas levando em consideração o número de verdadeiros positivos (*tp*), verdadeiros negativos (*tn*), falsos positivos (*fp*) e falsos negativos (*fn*). Sendo que os “verdadeiros” dizem respeito ao acertos das classes “positiva” (1) e “negativa” (0), e os “falsos” em relação as entradas classificadas erroneamente em cada classe.

A taxa de acerto (4.6), ou acurácia, diz respeito ao número de entradas previstas corretamente sobre o número total de previsões.

$$A = \frac{tp + tn}{tp + fp + tn + fn} \quad (4.6)$$

A precisão (4.7) é o número de acertos na classe positiva sobre o número total de previsões dessa classe, em outras palavras, de todas as entradas em que a saída da rede foi “1”, quantas foram previsões corretas. Também é costumeiro calcular a precisão da classe negativa, que é conhecida como “valor preditivo negativo” onde ocorre a inversão

²<https://www.tensorflow.org>

³<https://keras.io>

das classes na fórmula.

$$P = \frac{tp}{tp + fp} \quad (4.7)$$

Revocação (4.8) diz respeito ao número de valores corretamente previstos de uma determinada classe dentre o número total de ocorrências existentes daquela classe. Assim como a precisão pode ser calculada para ambas as classes.

$$R = \frac{tp}{tp + fn} \quad (4.8)$$

A medida F1 (4.9) é uma média harmônica entre precisão e revocação e é uma das métricas mais úteis para algoritmos de classificação ou previsão, pois permite uma avaliação acima de problemas de enviesamento em relação à uma determinada classe, e também permite a priorização entre precisão e revocação em problemas que isso se faça necessário.

$$F1 = 2 \frac{P * R}{P + R} \quad (4.9)$$

Para fins de comparação e poder averiguar se o modelo proposto oferece algum tipo de benefício ou não em relação à outros algoritmos de inteligência computacional, serão feitas comparações em relação à algoritmos de aprendizado de máquina mais tradicionais e sem a habilidade de memória de curto prazo. Os escolhidos para *baseline* foram *Multi-layer Perceptron* (MLP) e *RandomForest*.

O SVM também foi avaliado para comparação, contudo devido a dimensão da entrada houve dificuldade de convergência no processo de treinamento, sem nenhum tipo de otimização na configuração do modelo. Por esse motivo seus resultados foram descartados.

4.5.1 Testes estatísticos

Para a avaliação do modelo serão feitas múltiplas execuções e as métricas analisadas em relação à sua média e desvio padrão.

Muitas vezes, mesmo que hajam diferenças nos resultados, estes podem ser muito próximos fazendo surgir a dúvida se há predominância de um sobre o outro ou se é apenas uma questão de aleatoriedade.

Para resolver esta questão, executamos testes estatísticos para verificar se existe uma diferença significativa entre os resultados do modelo proposto e dos *baselines*.

O método de teste escolhido foi o *Kruskal-Wallis* que é um teste não paramétrico utilizado para comparar múltiplas populações. Este teste não assume distribuição normal nos valores.

Este teste retorna um determinado valor (*p-value*) que determina a probabilidade dos resultados observados serem iguais ou mais extremos entre si. Se esse valor for menor que o nível de significância especificado (tipicamente 0,05), entende-se que existe diferença estatística entre as duas ou mais populações.

4.6 Análise financeira

Em problemas de investimento algorítmico é importante validar modelos de ponto de vista financeiro, pois estes nem sempre correlacionam com a qualidade preditiva do modelo.

Por vezes modelos com precisão baixa são capazes de apresentar lucros superiores desde que sejam capazes de detectar mudanças mais agudas nos preços.

Para avaliar do ponto de vista financeiro, foram calculados lucros utilizando uma estratégia bastante rudimentar. Caso a rede neural preveja uma alta, será executada uma operação de compra no momento atual t , e fechada (vendida) invariavelmente no momento seguinte $t + 1$.

$$retorno = fechamento_{t+1} - fechamento_t \quad (4.10)$$

Por isso, para colocar esses resultados em perspectiva, eles serão comparados com outras estratégias de investimento simples e tradicionais, também sobre dados históricos.

Estas estratégias são:

- **Buy-and-hold:** Assumir posição de compra no período t_1 e fechar a posição em t_n .
- **Seguindo a distribuição:** Modelo que sorteia operar ou não com probabilidades de acordo com a distribuição dos dados.
- **Estratégia ingênua:** Repetir o mesmo ocorrido no período anterior, se houve alta é feita uma operação de compra, caso contrário não é feita nenhuma operação.

Sendo assim, uma análise dos retornos tanto em termos gerais quando em operação de investimento é necessária, assim como sobre a evolução do patrimônio sobre o tempo de forma a ver fatores como o risco ao qual se é exposto.

Esta forma de avaliação teórica será o sobre o resultado financeiro calculado de forma ingênua sobre os mesmos dados históricos, sem levar em consideração nuances do mercado financeiro como liquidez, prioridade de execução e custos operacionais

Capítulo 5

Experimentos

Este capítulo descreve os experimentos realizados e resultados obtidos utilizando o modelo descrito no Capítulo anterior.

Os dados utilizados para os experimentos descritos a seguir foram dados históricos da bolsa de valores. Foram coletados dados de *candles* de 15 minutos do ano de 2014 para os ativos listados na Tabela 5.1.

Para os experimentos, foram utilizados 1.280 *candles* para treinamento e 640 para teste. Cada 640 *candles* correspondem a aproximadamente um mês de negociação, o mês de Dezembro de 2014 foi escolhido para teste e os anteriores para treinamento.

Os experimentos apresentados no decorrer deste capítulo foram realizados em uma máquina Core i7 2.4 GHz, 8GB RAM.

E além dos experimentos apresentados, também foram realizados experimentos utilizando configurações diferentes para o modelo com o intuito de testar diferentes variantes para chegar à melhor possível, que foi descrita anteriormente. E também experimentos com períodos distintos, para avaliar a consistência do modelo, contudo apresentando apenas o que foi mencionado anteriormente a seguir.

5.1 Caracterização e análise dos dados

Os dados de entrada usados pelo algoritmo são os *candles* de 15 minutos juntamente a indicadores técnicos gerados a a partir deles. E a saída é um sinal indicando se houve alta ou não.

A Tabela 5.1 mostra um sumário da evolução dos preços dos ativos no período utilizado para experimentos. BOVA11 e PETR4 tiveram uma desvalorização acentuada quando observado o preço inicial do período de treino em relação ao preço final do período de teste. É possível observar também que já havia uma desvalorização ao final

do período de treino e o período de teste apenas seguiu essa tendência. BBDC4 e ITUB4 tem padrões muito similares, uma alta acentuada durante o período de treino e em seguida uma queda considerável, contudo ainda tendo uma variação positiva quando olhamos apenas a diferença de preço inicial e final. CIEL3 também seguiu um padrão parecido, porém com variações menos drásticas.

Tabela 5.1. Ativos utilizados e sua variação de preço

Símbolo	Preço inicial de treino	Preço inicial de teste	Preço final de teste
BOVA11	R\$ 55,26	R\$ 53,54	R\$ 48,54
BBDC4	R\$ 30,25	R\$ 35,68	R\$ 30,79
CIEL3	R\$ 32,34	R\$ 35,83	R\$ 33,98
ITUB4	R\$ 29,65	R\$ 34,64	R\$ 30,73
PETR4	R\$ 18,39	R\$ 13,26	R\$ 10,03

Nas Figuras 5.1, 5.2, 5.3, 5.4 e 5.5 podemos ver o comportamento do preço em maior detalhe. Em geral, as séries de preços apresentam uma alta volatilidade, o que pode ser considerado um reflexo do momento de instabilidade política e econômica observados no país durante o período dos experimentos, que coincidiu com as eleições presidenciais de 2014.

Figura 5.1. Evolução do preço de BOVA11





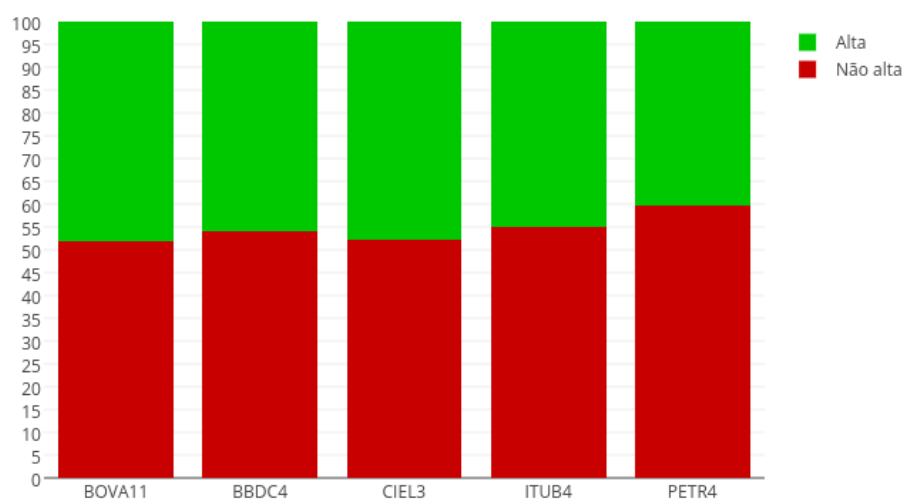
Figura 5.2. Evolução do preço de BBDC4**Figura 5.3.** Evolução do preço de CIEL3

Figura 5.4. Evolução do preço de ITUB4**Figura 5.5.** Evolução do preço de PETR4

Figura 5.6. Distribuição das classes por ativo no treino**Figura 5.7.** Distribuição das classes por ativo no teste

Também é interessante observar que os gráficos de BBDC4 e ITUB4 são extremamente similares, isso acontece pois ambos são da mesma indústria e esse fato geralmente reflete em uma alta correlação nos movimentos de preço.

Já PETR4, com exceção do início do período, demonstra uma tendência quase continua de queda, terminando com aproximadamente metade do valor que chegou a valer durante o período. E isso é uma relação direta ao fato da empresa ter sido pivô de escândalos de corrupção nos últimos anos.

A distribuição das classes (Figura 5.6) no treino é bastante balanceada para os ativos selecionados, todos tem um maior número de instâncias de classe de não alta, mas a proporção está entre próxima a 50% e abaixo de 55% para todos os ativos.

Para os dados de teste (Figura 5.7) existe uma predominância maior de classe de não alta, chegando a quase 60% para PETR4 e por volta de 55% para ambos BBDC4 e ITUB4.

A proporção similar entre as classes é importante para evitar problemas de enviesamento a uma das classes, que por vezes resulta em um modelo com taxa de acerto alta mas que prevê apenas uma das classes.

É importante salientar que o que é referido como período de treino nesta Seção diz respeito aos dados utilizados como treino na janela inicial. Como o modelo é baseado em janelas deslizantes, esse conjunto de dados sofre mutação a cada janela, descartando um dia de negociações no início do vetor e adicionando o dia mais recente ao final.

Estes dados evidenciam um período bastante adverso para investimentos, onde usualmente é difícil obter lucro e muitos investidores optam por se abster de negociações no mercado de ações. E em especial para um modelo como o proposto, que procura obter lucro apenas em situações de alta, o nível de dificuldade de se obter resultados positivos é ainda maior.

5.2 Resultados experimentais

Os experimentos deste algoritmo foram feitos separando parte dos dados de *candle* para validação do modelo.

Foram realizadas dez execuções por ativo, e os resultados coletados foram analisados em relação à sua média e desvio padrão.

A Tabela 5.2 com as métricas de avaliação dos resultados em função da classe 1 (previsão de alta) mostra a qualidade dos resultados em critérios de previsão.

Em termos de acurácia os resultados variaram entre 0,53 (CIEL3) e 0,559 (BBDC4). BOVA11 teve uma acurácia de 0,546, para ITUB4 o valor obtido foi 0,545

e 0,533 para PETR4.

A precisão teve um desvio padrão um pouco maior, entre 0,475 (ITUB4) e 0,563 (PETR4). BOVA11 também teve um dos valores mais altos, 0,560 assim como BBDC4 (0,553). Já CIEL3 também teve uma precisão baixa em 0,476.

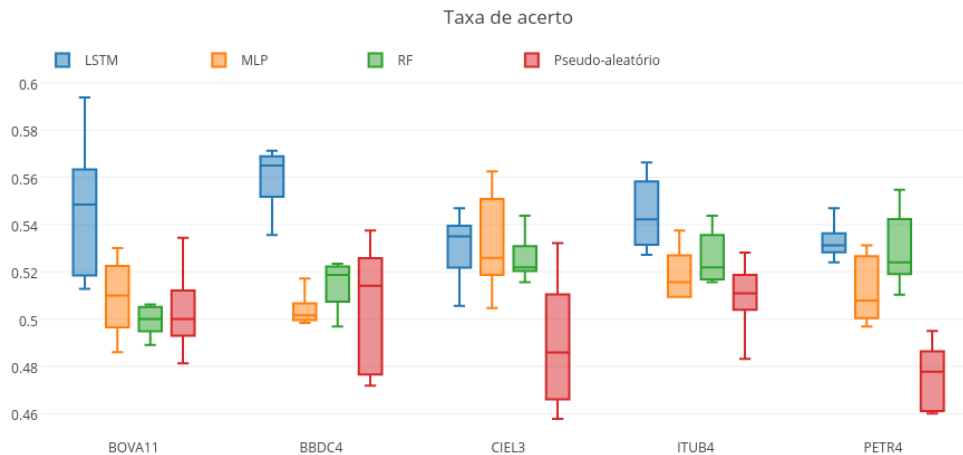
Já a revocação em geral foi baixa, significando que o número de classes de alta que foram detectadas pelo modelo foi baixa. Isso é traduzido em ausência de lucro mas também pode significar menos chance de prejuízo já que o modelo arrisca menos.

Os valores ficaram entre 0,129 (BBDC4) e 0,350 (BOVA11). E para os outros ativos foram 0,134 (ITUB4), 0,137 (CIEL3) e 0,231 (PETR4).

Tabela 5.2. Métricas de avaliação

Ativo	Acurácia	Precisão	Revocação	Medida F1
BOVA11	0,546	0,560	0,350	0,431
BBDC4	0,559	0,553	0,129	0,209
ITUB4	0,545	0,475	0,134	0,209
CIEL3	0,530	0,476	0,137	0,213
PETR4	0,533	0,563	0,231	0,327

Figura 5.8. Taxa de acerto por ativos




Quando os resultados são comparados com outros modelos de previsão, como o MLP, *Random Forest*, e o pseudo-aleatório como demonstrado na Figura 5.8, pode-se observar que a mediana é superior a todos eles para qualquer ativo. Mesmo que em alguns deles o valor esteja bastante próximo, isso corrobora para a hipótese de

que redes LSTM podem apresentar ganho de resultados ainda que por vezes não seja significativo.

E mesmo que não haja diferença considerável entre os resultados é importante destacar que em nenhuma das vezes os resultados obtidos através de redes LSTM foram inferiores aos *baselines* em termos de acurácia.

Figura 5.9. Coeficiente de variação do acerto



Já ao avaliar o coeficiente de variação (desvio padrão sobre a média), podemos notar na Figura 5.9 que a rede LSTM, assim como os *baselines*, tem valores baixos, variando entre 0,01 e 0,05. O ideal é que o desvio padrão seja o menor possível, o que significa um maior nível de previsibilidade em relação ao desempenho do modelo.

Conforme citado no capítulo anterior, a diferença de resultados em muitos experimentos é próxima, não havendo clareza se um é realmente melhor que o outro ou não.

Para isso, executamos testes estatísticos usando o método de *Kruskal-Wallis* para verificar se existe diferença significativa entre eles ou não, comparando o modelo proposto com cada um dos *baselines* para cada ativo.

Nesse método quando o valor é menor que 0,05 significa que existe uma predominância de um modelo sobre o outro, e temos a Figura 5.10 mostrando o resultado das comparações.

Em relação ao modelo pseudo-aleatório houve predominância para todos os ativos, comparado ao *Random Forest* os resultados foram estatisticamente similares para três

dos cinco ativos e para dois comparando ao MLP.

Para PETR4 e CIEL3 os outros modelos de aprendizado de máquina se comportaram de forma similar à LSTM, e para ITUB4 apenas o *Random Forest*. Já para BOVA11 e BBDC4 houve melhores em relação à todos os *baselines*.

Figura 5.10. Diferença estatística - Kruskal-Wallis

Statistical Test (Kruskal-Wallis)					
	BOVA11	BBDC4	CIEL3	ITUB4	PETR4
Pseudo-aleatório	0.028	0.016	0.028	0.016	0.009
RF	0.009	0.009	0.346	0.094	1.0
MLP	0.047	0.009	0.834	0.028	0.059

Para que um modelo de previsão no mercado financeiro seja considerado bom, ainda mais importante que a taxa de acerto ou outra métrica de previsão, é que o modelo apresente bons resultados financeiros.

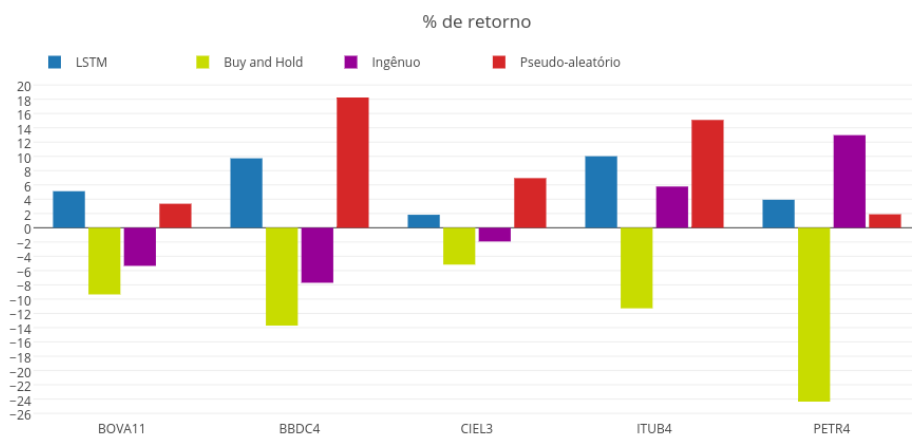
Para avaliar isto, simulamos quais seriam os retornos financeiros relativos à uma aplicação hipotética nesses ativos quando o modelo prever classe de alta, e vendendo 15 minutos no futuro. Os resultados foram calculados com base na compra de um único lote de ações (100) por ativo.

A Figura 5.11 demonstra o retorno médio por ativo, e o compara com estratégias simples de investimento. Com exceção do modelo pseudo-aleatório que tem resultados melhores em três dos cinco ativos, a rede LSTM tem resultados acima dos outros *baselines* na maioria das vezes.

Na Figura 5.12 vemos o retorno médio por operação, nesse gráfico excluimos o *Buy & Hold* pois este sempre se resume a apenas uma operação. Neste caso, o modelo com a rede LSTM tem resultados melhores na maior parte dos casos, apenas perdendo para o pseudo-aleatório em dois ativos (BBDC4 e CIEL3).

Isso é um indicativo que a rede tem maior capacidade de detectar altas mais significativas. O fato de estar com resultados positivos para todos os ativos é um bom indicativo de baixo risco.

E por fim, a Figura 5.13 mostra um gráfico contendo o prejuízo máximo em termos percentuais durante as execuções, em outras palavras, o momento que o capital

Figura 5.11. Retornos financeiros por ativo

chegou a seu menor valor. O ideal é que esse valor seja o menor possível em termos absolutos, pois quanto maior, maior será o risco ao qual o investidor está exposto.

Neste caso também a rede LSTM teve resultados superiores aos outros modelos na maior parte das vezes.



Figura 5.12. Retornos financeiros médios por ativo

Figura 5.13. *Max Drawdown*



Neste Capítulo pudemos ver que o uso de redes LSTM pode sim ser considerado vantajoso para prever comportamento de séries temporais financeiras. Tanto em métricas de previsão quanto financeiras, o modelo usando LSTM apresentou resultados superiores mais vezes em relação aos modelos com que foi comparado.

Ainda que em alguns exemplos as métricas observadas para as redes LSTM não tiveram ganhos significativos, ou mesmo foram inferiores, acreditamos que no geral se trata de um modelo mais apropriado para lidar com problemas caracterizados por séries temporais dada a sua natureza.

No Capítulo a seguir é apresentada a conclusão deste trabalho, juntamente às perspectivas de trabalhos futuros que consideramos promissoras.

Capítulo 6

Conclusão

Este trabalho teve como premissa propor um modelo de previsão para o mercado financeiro utilizando como base duas técnicas que usualmente não são exploradas em conjunto, redes LSTM e análise técnica.

A ideia é que um algoritmo de rede recorrente robusto como a LSTM poderia resultar em melhores previsões ao fazer uso de sua capacidade de memória de curto prazo.

Para validar esta hipótese foi realizada uma série de experimentos empíricos utilizando dados reais da Bolsa de Valores de São Paulo, e realizamos uma análise extensa em cima dos resultados.

Podemos observar que, em geral, o modelo proposto nesse trabalho tem resultados melhores que os *baselines* com algumas exceções. Os resultados podem ser considerados promissores e provou-se capaz de prever com qualidade quando comparado com outras abordagens apresentadas na literatura.

Apesar da dimensionalidade da entrada ser grande, o algoritmo demonstrou uma capacidade satisfatória de aprender a partir dela sem a necessidade de técnicas de redução de dimensionalidade como seleção de *features* por exemplo.

Quando o comparamos com outros métodos de aprendizado de máquina mais tradicionais e juntamente a um modelo pseudo-aleatório, podemos concluir que houve um ganho considerável em termos de acurácia. Entretanto, acreditamos que o desvio padrão poderia ser menor.

Analisando os resultados financeiros, é importante destacar que o modelo foi capaz de mantê-los positivos para todos os ativos, mesmo considerando que não necessariamente obteve melhores resultados que alguns dos *baselines*.

Outro aspecto positivo é que ele resultou em um alto retorno médio por operação, significando que possuiu mais sucesso detectando variações mais agudas, o que é

extremamente importante quando se levar em conta custos de transação e taxas.

Além disso, quando observam-se as perdas máximas, que é uma medida de risco, o modelo usando LSTM obteve resultados melhores comparados a outras estratégias.

6.1 Contribuições realizadas

Neste trabalho pudemos idealizar e projetar um novo modelo de previsão de tendências na bolsa de valores à base de dados históricos de preço e fazendo uso de um algoritmo de redes neurais recorrentes.

Além disso, validamos o modelo através de experimentos e apresentamos uma análise de seu desempenho, comparando-o com outros modelos de aprendizado de máquina e estratégias de investimento.

Tivemos também a oportunidade de apresentar o trabalho em eventos como Econophysics Colloquium 2016¹ e KDMile 2016², neste último também publicamos um artigo científico relacionado à mesma pesquisa.

6.2 Trabalhos futuros

O campo de estudos de previsões em bolsas de valores oferece uma infinidade de possibilidades de pesquisa. Desta maneira, esse trabalho pode ser estendido de diversas formas.

No que diz respeito ao aumento da qualidade das previsões, problemas de aprendizado de máquina no geral dependem muito da qualidade da entrada. Dado isso, uma das possibilidades é trabalhar nos atributos, estudando mais formas de reduzir ruído na série temporal e possivelmente melhores maneiras de normalizar ou representar cada um deles.

Pode ser também que existam outros atributos que ajudem a melhorar os resultados e que podem ser estudados, como por exemplo indicadores de sentimento de notícias relacionadas a ativos, volume de dados relacionados em redes sociais ou mesmo sobre buscas em motores de busca na *web*.

É possível que alguns dos atributos utilizados estejam causado um efeito adverso nos resultados, e possivelmente uma análise individual de cada possa determinar se isso é um fato ou não.

¹http://www.ictp-saifr.org/?page_id=11382

²<http://cin.ufpe.br/bracis2016/detailed-program-kdmile.html>

Do ponto de vista financeiro, é notório que a estratégia de investimento é tão importante quanto a prever corretamente o comportamento do mercado. A estratégia usada neste trabalho foi bastante rudimentar, e é possível que com opções diferentes esses resultados sejam consideravelmente melhores.

Estratégias com *stop gain* e *stop loss* tem potencial para minimizar prejuízos sem limitar os ganhos.

Uma outra opção que impactaria tanto as previsões quanto os resultados financeiros seria alterar o modelo para prever apenas ganhos acima de um determinado valor.

Também seria interessante validar o modelo utilizando simuladores de mercado de ações e eventualmente até mesmo em um ambiente real. De forma a colocá-lo sob a perspectiva de um ambiente mais realista, onde nem sempre as ordens são executadas, ou não são executadas com os valores esperados.

Referências Bibliográficas

- Adebiyi Ayodele A., Ayo Charles K., A. M. O. (2012). Stock price prediction using neural network with hybridized market indicators. *Journal of Emerging Trends in Computing and Information Sciences*, 3(1):1–9.
- Akita, R.; Yoshihara, A.; Matsubara, T. & Uehara, K. (2016). Deep learning for stock prediction using numerical and textual information. Em *2016 IEEE/ACIS 15th International Conference on Computer and Information Science (ICIS)*, pp. 1–6.
- Allen, F. & Karjalainen, R. (1999). Using genetic algorithms to find technical trading rules. *Journal of Financial Economics*, 51(2):245 – 271. ISSN 0304-405X.
- Bailey, D. H.; Borwein, J. M.; Lopez de Prado, M. & Zhu, Q. J. (2015). The probability of backtest overfitting. *Journal of Computational Finance*.
- Batres-Estrada, B. (2015). Deep learning for multivariate financial time series. Dissertação de mestrado, KTH, Mathematical Statistics.
- Bebarta, D. K.; Biswal, B. & Dash, P. K. (2015). Polynomial based functional link artificial recurrent neural network adaptive system for predicting indian stocks. *Int. J. Computational Intelligence Systems*, 8(6):1004–1016.
- Bengio, Y. (2009). Learning deep architectures for AI. *Foundations and trends in Machine Learning*, 2(1):1–127.
- Bengio, Y.; Simard, P. & Frasconi, P. (1994). Learning long-term dependencies with gradient descent is difficult. *IEEE Transactions on Neural Networks*, 5(2):157–166.
- Bernal, O.; Fok, S. & Pidaparthi, R. (2012). Financial market time series prediction with recurrent neural networks.
- Biondo, A. E.; Pluchino, A.; Rapisarda, A. & Helbing, D. (2013). Are Random Trading Strategies More Successful than Technical Ones? *PLoS ONE*, 8:e68344.

- Bússola do Investidor (2007). Bússola do investidor. <https://www.bussoladoinvestidor.com.br/>. Acessado em 30 de Novembro de 2015.
- Cedervall, F. (2012). Machine learning for technical stock analysis.
- Chen, K.; Zhou, Y. & Dai, F. (2015). A lstm-based method for stock returns prediction: A case study of china stock market. Em *Big Data (Big Data), 2015 IEEE International Conference on*, pp. 2823–2824.
- Corp., M. S. (2000). Metatrader. <http://www.metatrader5.com/>. Acessado em 30 de Setembro de 2015.
- Easley, D.; Lopez de Prado, M. & O’Hara, M. (2015). Discerning information from trade data. *Journal of Computational Finance*.
- Erhan, D.; Bengio, Y.; Courville, A. & Vincent, P. (2009). Visualizing higher-layer features of a deep network. *Dept. IRO, Université de Montréal, Tech. Rep.*
- Fama, E. F. & Malkiel, B. G. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2):383–417. ISSN 1540-6261.
- Giles, C. L.; Lawrence, S. & Tsoi, A. C. (2001). Noisy time series prediction using recurrent neural networks and grammatical inference. *Machine Learning*, 44(1/2):161–183.
- Glantz, M. & Kissell, R. (2013). *Multi-asset Risk Modeling*. Academic Press, 1 edição. ISBN 978-0-12-401690-3.
- Gomide, J. S. A. (2012). Mineração de redes sociais para detecção e previsão de eventos reais. Dissertação de mestrado, Universidade Federal de Minas Gerais (UFMG).
- Graves, A. (2012). *Supervised Sequence Labelling with Recurrent Neural Networks*, volume 385 of *Studies in Computational Intelligence*. Springer. ISBN 978-3-642-24796-5.
- Graves, A.; Liwicki, M.; Fernández, S.; Bertolami, R.; Bunke, H. & Schmidhuber, J. (2009). A novel connectionist system for unconstrained handwriting recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 31(5):855–868. ISSN 0162-8828.
- Greff, K.; Srivastava, R. K.; Koutník, J.; Steunebrink, B. R. & Schmidhuber, J. (2015). LSTM: A search space odyssey. *arXiv preprint arXiv:1503.04069*.

- Heaton, J. B.; Polson, N. G. & Witte, J. H. (2016). Deep learning in finance. *CoRR*, abs/1602.06561.
- Hinton, G. E. (2012). A practical guide to training restricted boltzmann machines. Em Montavon, G.; Orr, G. B. & Müller, K.-R., editores, *Neural Networks: Tricks of the Trade (2nd ed.)*, volume 7700 of *Lecture Notes in Computer Science*, pp. 599–619. Springer.
- Hinton, G. E. & Salakhutdinov, R. R. (2006). Reducing the dimensionality of data with neural networks. *Science*, 313(5786):504–507.
- Hochreiter, S. & Schmidhuber, J. (1997). Long short-term memory. *Neural Comput.*, 9(8):1735–1780. ISSN 0899-7667.
- Iuhasz, G.; Tirea, M. & Negru, V. (2012). Neural network predictions of stock price fluctuations. *2011 13th International Symposium on Symbolic and Numeric Algorithms for Scientific Computing*, 0:505–512.
- jae Kim, K. (2003). Financial time series forecasting using support vector machines. *Neurocomputing*, 55(1–2):307 – 319. ISSN 0925-2312. Support Vector Machines.
- Jaybhay, K. M.; Argiddi, R. V. & Apte, S. S. (2012). Stock market prediction model by combining numeric and news textual mining. *International Journal of Computer Applications*, 57(19):16–22.
- Kamijo, K. & Tanigawa, T. (1990). Stock price pattern recognition-a recurrent neural network approach. Em *Neural Networks, 1990., 1990 IJCNN International Joint Conference on*, pp. 215–221 vol.1.
- Karpathy, A.; Johnson, J. & Li, F. (2015). Visualizing and understanding recurrent networks. *CoRR*, abs/1506.02078.
- Khaidem, L.; Saha, S. & Dey, S. R. (2016). Predicting the direction of stock market prices using random forest. *CoRR*, abs/1605.00003.
- Kirkpatrick, C. & Dahlquist, J. (2006). *Technical Analysis: The Complete Resource for Financial Market Technicians*. FT Press, first edição. ISBN 0131531131.
- Klapper-Rybicka, M.; Schraudolph, N. N. & Schmidhuber, J. (2001). Unsupervised learning in LSTM recurrent neural networks. Em *In*, pp. 684–691. Springer-Verlag.
- Larsen, J. I. & Langseth, S. H. (2010). Predicting stock prices using technical analysis and machine learning.

- Lo, A. & MacKinlay, A. (1999). *A non-random walk down Wall Street*. Princeton Univ. Press, Princeton, NJ [u.a.]. ISBN 0691057745.
- Luca Di Persio, O. H. (2016). Artificial neural networks approach to the forecast of stock market price movements. *International Journal of Economics and Management Systems*, 1:158–162.
- Machado, E. J.; Pereira, A. C. M.; Castilho, D.; Silva, E. & Brandão, H. (2015). Proposal and implementation of new trading strategies for stock markets using web data. Em *Proceedings of the 21st Brazilian Symposium on Multimedia and the Web, WebMedia '15*, pp. 113–120, New York, NY, USA. ACM.
- Malkiel, B. G. (1973). *A Random Walk Down Wall Street*. Norton, New York.
- Melo, B. (2012). Considerações cognitivas nas técnicas de previsão no mercado financeiro. *Universidade Estadual de Campinas*.
- Pang, B.; Lee, L. & Vaithyanathan, S. (2002). Thumbs up?: Sentiment classification using machine learning techniques. Em *Proceedings of the ACL-02 Conference on Empirical Methods in Natural Language Processing - Volume 10, EMNLP '02*, pp. 79–86, Stroudsburg, PA, USA. Association for Computational Linguistics.
- Pommerenzenbaum, I. R. (2014). Redes neurais artificiais na predição das principais séries do índice ibovespa e suas aplicações em sistemas automatizados de negociação. Dissertação de mestrado, Universidade Federal do Rio de Janeiro.
- Rather, A. M.; Agarwal, A. & Sastry, V. (2015). Recurrent neural network and a hybrid model for prediction of stock returns. *Expert Systems with Applications*, 42(6):3234 – 3241. ISSN 0957-4174.
- Rechenthin, M. & of Business, H. B. T. C. (2014). *Machine-learning Classification Techniques for the Analysis and Prediction of High-frequency Stock Direction*.
- Saad, E. W.; Prokhorov, D. V.; Wunsch, D. C. & II (1998). Comparative study of stock trend prediction using time delay, recurrent and probabilistic neural networks. *IEEE TRANSACTIONS ON NEURAL NETWORKS*, 9(6):1456–1470.
- Schumaker, R. P. & Chen, H. (2009). Textual analysis of stock market prediction using breaking financial news: The azfin text system. *ACM Trans. Inf. Syst.*, 27(2):12:1–12:19. ISSN 1046-8188.

- Sharang, A. & Rao, C. (2015). Using machine learning for medium frequency derivative portfolio trading. *CoRR*, abs/1512.06228.
- Sutskever, I. (2013). *Training recurrent neural networks*. Tese de doutorado, University of Toronto.
- Sutskever, I.; Vinyals, O. & Le, Q. V. (2014). Sequence to sequence learning with neural networks. Em *Advances in Neural Information Processing Systems*, pp. 3104–3112.
- TicTacTec (1999). Ta-lib. <http://ta-lib.org/>. Acessado em 30 de Setembro de 2015.
- Wang, J.-H. & Leu, J.-Y. (1996). Stock market trend prediction using arima-based neural networks. Em *Neural Networks, 1996., IEEE International Conference on*, volume 4, pp. 2160–2165 vol.4.
- Wikipedia (2004). Wikipedia, the free encyclopedia.
- Yoshihara, A.; Fujikawa, K.; Seki, K. & Uehara, K. (2014). Predicting stock market trends by recurrent deep neural networks. Em Pham, D.-N. & Park, S.-B., editores, *PRICAI 2014: Trends in Artificial Intelligence*, volume 8862 of *Lecture Notes in Computer Science*, pp. 759–769. Springer International Publishing.

Apêndice A

Indicadores técnicos

Código	Nome do Indicador
AD	Chaikin A/D Line
ADOSC	Chaikin A/D Oscillator
ADX	Average Directional Movement Index
ADXR	Average Directional Movement Index Rating
APO	Absolute Price Oscillator
AROON	Aroon
AROONOSC	Aroon Oscillator
ATR	Average True Range
AVGPRICE	Average Price
BBANDS	Bollinger Bands
BETA	Beta
BOP	Balance Of Power
CCI	Commodity Channel Index
CDL2CROWS	Two Crows
CDL3BLACKCROWS	Three Black Crows
CDL3INSIDE	Three Inside Up/Down
CDL3LINESTRIKE	Three-Line Strike
CDL3OUTSIDE	Three Outside Up/Down
CDL3STARSINSOUTH	Three Stars In The South
CDL3WHITESOLDIERS	Three Advancing White Soldiers
CDLABANDONEDBABY	Abandoned Baby
CDLADVANCEBLOCK	Advance Block
CDLBELTHOLD	Belt-hold

Código	Nome do Indicador
CDLBREAKAWAY	Breakaway
CDLCLOSINGMARUBOZU	Closing Marubozu
CDLCONCEALBABYSWALL	Concealing Baby Swallow
CDLCOUNTERATTACK	Counterattack
CDLDARKCLOUDCOVER	Dark Cloud Cover
CDLDOJI	Doji
CDLDOJISTAR	Doji Star
CDLDRAGONFLYDOJI	Dragonfly Doji
CDLENGULFING	Engulfing Pattern
CDLEVENINGDOJISTAR	Evening Doji Star
CDLEVENINGSTAR	Evening Star
CDLGAPSIDESIDEWHITE	Up/Down-gap side-by-side white lines
CDLGRAVESTONEDOJI	Gravestone Doji
CDLHAMMER	Hammer
CDLHANGINGMAN	Hanging Man
CDLHARAMI	Harami Pattern
CDLHARAMICROSS	Harami Cross Pattern
CDLHIGHWAVE	High-Wave Candle
CDLHIKKAKE	Hikkake Pattern
CDLHIKKAKEMOD	Modified Hikkake Pattern
CDLHOMINGPIGEON	Homing Pigeon
CDLIDENTICAL3CROWS	Identical Three Crows
CDLINNECK	In-Neck Pattern
CDLINVERTEDHAMMER	Inverted Hammer
CDLKICKING	Kicking
CDLKICKINGBYLENGTH	Kicking - bull/bear determined by the longer marubozu
CDLLADDERBOTTOM	Ladder Bottom
CDLLONGLEGGEDDOJI	Long Legged Doji
CDLLONGLINE	Long Line Candle
CDLMARUBOZU	Marubozu
CDLMATCHINGLOW	Matching Low
CDLMATHOLD	Mat Hold
CDLMORNINGDOJISTAR	Morning Doji Star
CDLMORNINGSTAR	Morning Star

Código	Nome do Indicador
CDLONNECK	On-Neck Pattern
CDLPIERCING	Piercing Pattern
CDLRICKSHAWMAN	Rickshaw Man
CDLRISEFALL3METHODS	Rising/Falling Three Methods
CDLSEPARATINGLINES	Separating Lines
CDLSHOOTINGSTAR	Shooting Star
CDLSHORTLINE	Short Line Candle
CDLSPINNINGTOP	Spinning Top
CDLSTALLEDPATTERN	Stalled Pattern
CDLSTICKSANDWICH	Stick Sandwich
CDLTAKURI	Takuri (Dragonfly Doji with very long lower shadow)
CDLTASUKIGAP	Tasuki Gap
CDLTHRUSTING	Thrusting Pattern
CDLTRISTAR	Tristar Pattern
CDLUNIQUE3RIVER	Unique 3 River
CDLUPSIDEGAP2CROWS	Upside Gap Two Crows
CDLXSIDEGAP3METHODS	Upside/Downside Gap Three Methods
CMO	Chande Momentum Oscillator
CORREL	Pearson's Correlation Coefficient (r)
DEMA	Double Exponential Moving Average
DX	Directional Movement Index
EMA	Exponential Moving Average
HT_DCPERIOD	Hilbert Transform - Dominant Cycle Period
HT_DCPHASE	Hilbert Transform - Dominant Cycle Phase
HT_PHASOR	Hilbert Transform - Phasor Components
HT_SINE	Hilbert Transform - SineWave
HT_TRENDLINE	Hilbert Transform - Instantaneous Trendline
HT_TRENDMODE	Hilbert Transform - Trend vs Cycle Mode
KAMA	Kaufman Adaptive Moving Average
LINEARREG	Linear Regression
LINEARREG_ANGLE	Linear Regression Angle
LINEARREG_INTERCEPT	Linear Regression Intercept
LINEARREG_SLOPE	Linear Regression Slope
MA	All Moving Average

Código	Nome do Indicador
MACD	Moving Average Convergence/Divergence
MACDEXT	MACD with controllable MA type
MACDFIX	Moving Average Convergence/Divergence Fix 12/26
MAMA	MESA Adaptive Moving Average
MAX	Highest value over a specified period
MAXINDEX	Index of highest value over a specified period
MEDPRICE	Median Price
MFI	Money Flow Index
MIDPOINT	MidPoint over period
MIDPRICE	Midpoint Price over period
MIN	Lowest value over a specified period
MININDEX	Index of lowest value over a specified period
MINMAX	Lowest and highest values over a specified period
MINMAXINDEX	Indexes of lowest and highest values over a specified period
MINUS_DI	Minus Directional Indicator
MINUS_DM	Minus Directional Movement
MOM	Momentum
NATR	Normalized Average True Range
OBV	On Balance Volume
PLUS_DI	Plus Directional Indicator
PLUS_DM	Plus Directional Movement
PPO	Percentage Price Oscillator
ROC	Rate of change : $((\text{price}/\text{prevPrice})-1)*100$
ROCP	Rate of change Percentage: $(\text{price}-\text{prevPrice})/\text{prevPrice}$
ROCR	Rate of change ratio: $(\text{price}/\text{prevPrice})$
ROCR100	Rate of change ratio 100 scale: $(\text{price}/\text{prevPrice})*100$
RSI	Relative Strength Index
SAR	Parabolic SAR
SAREXT	Parabolic SAR - Extended
SMA	Simple Moving Average
STDDEV	Standard Deviation
STOCH	Stochastic
STOCHF	Stochastic Fast
STOCHRSI	Stochastic Relative Strength Index

Código	Nome do Indicador
SUM	Summation
T3	Triple Exponential Moving Average (T3)
TEMA	Triple Exponential Moving Average
TRANGE	True Range
TRIMA	Triangular Moving Average
TRIX	1-day Rate-Of-Change (ROC) of a Triple Smooth EMA
TSF	Time Series Forecast
TYPPRICE	Typical Price
ULTOSC	Ultimate Oscillator
VAR	Variance
WCLPRICE	Weighted Close Price
WILLR	Williams' %R
WMA	Weighted Moving Average

Tabela A.1. Indicadores técnicos gerados pela TA-Lib [TicTacTec, 1999]